

گزارش فاز اول

بنفشه کریمیان

94521189

## 1. دیتا ست

دیتاست انتخابی برای این پروژه کتاب ادبیات چهارم دبستان برای سال 1343 و 1391 است .  
برای گرفتن متن این دو کتاب به دلیل عکس بودن از ابزار googleDrive استفاده شده است.

## 2. فاز اول

برای فاز اول ابتدا نیم فاصله‌ها را با فاصله جایگزین کردیم. سپس یک لیست از نشانه‌ها مثل: ., : و ... و لیست دیگری از حروف اضافه‌ی فارسی مثل: با, به, در و اعداد تشکیل داده و این لیست‌ها را با فاصله جایگزین کردیم. سپس کارکترهای عربی مثل ء, ي و اعراب‌ها و نشانه‌ی جمع را حذف کردیم. (در این بین تمام حروف انگلیسی نیز به دلیل احتمال وجود خطا در OCR حذف شدند) پس از این مراحل wordmap را رسم کردیم اما مشاهده‌شد که فعل‌هایی مثل است, بود و ... توانر زیادی داشتند که برای جلوگیری از این مشکل فعل‌ها را نیز حذف کردیم. ابتدا دو واژه‌نمای زیر برای کلمات متواتر هر دیتاست به‌دست‌آمدند.



### واژه‌نما 1 کلمات متواتر پس از تمیز کردن دیتا در کتاب چهارم دبستان سال 1343

کسی راه استفاده پیدا آنها بزرگ خودش همه دور دست  
هیچ وقتی یکی اند تر دل شهر سال حرف کم آنان دریافت  
ایده خوش یا جای بچه دوست حالا ایران تو  
جمله چیزی حلال درخت فکر دربره ماهی نیز ام روزی روزی همان خوار بخت  
قلی کلاس الف قانون قرار زبان همین علی جا آورد  
نکته کلمه آموزی پرواز کودکان شتر خوب خیلی من  
زندگی وقت واژه فیل یعنی مرا دریا پرستوها موش قدر دیگران هر خانه



واژه‌نما 3 کلمات کتاب سال 1343 با اختلاف تواتر آن‌ها در کتاب سال 1391



واژه‌نما 4 کلمات کتاب سال 1391 با اختلاف تواتر آن‌ها در کتاب سال 1343

و در آخر دو واژه‌نما با همان روش بالا ولی با این تفاوت که عدد بدست آمده را از بزرگترین عدد کم می‌کنیم تا کلماتی که اختلاف کمی دارند قابل مشاهده باشند.



واژه‌نما 5 کلمات با اختلاف تواتر کم در کتاب سال 1343



واژه‌نما 6 کلمات با اختلاف تواتر کم در کتاب سال 1391

